

实证软件工程稿件编号 (由编辑插入)

开发者们都在聊些什么？Stack Overflow 热门话题与趋势分析

安东·巴鲁阿·斯蒂芬·W·托马斯·艾哈迈德
·E·哈桑

收到和接受的日期应在后面插入

抽象的编程问答 (Q&A) 网站，例如 Stack Overflow，利用用户的知识和专业技能来提供技术问题的答案。随着时间的推移，这些网站逐渐成为软件工程知识的宝库。这些知识库对于深入了解特定技术的使用情况以及开发者讨论的趋势至关重要。之前的研究主要侧重于分析问答网站中的用户活动或社交互动。然而，分析这些网站的实际文本内容可以帮助软件工程社区更好地理解开发者的想法和需求。在本文中，我们提出了一种分析 Stack Overflow 讨论文本内容的方法。我们使用一种统计主题建模技术——潜在狄利克雷分配 (LDA)，来自动发现开发者讨论中的主要主题。我们分析这些发现的主题及其随时间的变化关系和趋势，以深入了解开发社区。我们的分析使我们得出了许多有趣的观察结果，包括：开发者感兴趣的主体范围广泛，从工作到版本控制系统，再到 C# 语法；某些主题中的问题会引发其他主题的讨论；随着时间的推移，最受欢迎的主题是 Web 开发（尤其是 jQuery）、移动应用程序（尤其是 Android）、Git 和 MySQL。

关键词问答网站 · 知识库 · 主题模型 · 趋势分析

安东·巴鲁阿
加拿大金斯顿皇后大学计算机学院 K7L3N6 电子邮件: barua@cs.queensu.ca

斯蒂芬·W·托马斯
加拿大金斯顿皇后大学计算机学院 K7L3N6 电子邮件:
stthomas@cs.queensu.ca

艾哈迈德·E·哈桑
加拿大金斯顿皇后大学计算机学院 K7L3N6 电子邮件:
ahmed@cs.queensu.ca

1 简介

当今的软件工程领域由各种各样的技术、工具、语言 and 平台组成。开发人员需要精通各种技能和范式。即使是经验丰富的开发人员，也很难跟上这些范式的快速发展。

出于这些原因，开发人员经常求助于编程问答 (Q&A) 网站，例如 Stack Overflow (2012a)，向同行寻求帮助和建议，以应对他们面临的技术挑战。Stack Overflow 每月审核来自不同背景的开发人员发布的数十万条帖子，提出各种各样的问题。总的来说，这些帖子记录了开发人员的需求和想法——一个程序员需求的知识库。分析和理解这个知识库可以提供关于开发人员感兴趣主题的关键见解，例如他们喜欢哪些开发框架以及原因，什么样的工作环境最适合他们的需求，以及他们最喜欢的目标平台是什么。

研究人员已开始分析问答网站，例如 Stack Overflow 和 Yahoo! Answers (2012)，以发现用户行为模式 (Gyöngyi 等人 2008)、确定答案质量 (Shah 和 Pomerantz 2010)，并分析成功问答网站的设计特色 (Mamykina 等人 2011)。在本研究中，我们建议分析帖子的实际文本内容——一个丰富且尚未开发的信息来源——以确定开发者讨论的总体主题、主题趋势以及主题之间的交互模式。了解这些主题可以帮助编程语言和工具开发人员了解使用趋势，帮助商业供应商评估其产品的采用率，并帮助问答网站了解其信息内容的使用模式。

然而，分析如此庞大的知识库中的文本内容面临着诸多挑战。由于 Stack Overflow 包含数万名开发人员创建的数百万条帖子，庞大的数据量使得手动分析变得困难。此外，这些帖子以自然语言撰写，结构不规范，这使得大多数传统的数据挖掘技术难以有效发挥作用 (Hassan 2008)。

在本文中，我们提出了一种半自动化方法来分析此类知识库，其具体目标是揭示主要讨论主题、其潜在的依赖关系以及随时间变化的趋势。我们的方法基于潜在狄利克雷分配 (Blei 等人, 2003; Blei 和 Lafferty, 2009)，这是一种统计主题模型用于自动恢复主题(从文本文档语料库中找出知识图谱(即一组与现实世界概念近似的相关词))。潜在狄利克雷分配 (LDA) 已成功应用于许多领域，并被常规应用于数百万份文档 (Hall 等人, 2008 年; Griffiths 和 Steyvers, 2004 年)。我们定义并应用指标来衡量 LDA 发现的~~主题~~主题，从而对知识库进行定量和定性评估。例如，我们发现：移动和 Web 平台越来越流行；.NET 框架的流行度正在下降；而 Git 版本控制系统（在撰写本文时）与 SVN 一样流行。我们还发现，开发人员讨论的主题范围很广，从 C# 语法到移动开发

平台与工作相关经验的结合。我们在线提供数据集和结果，以便于复制我们的研究成果 (Thomas 2012a)。

我们的研究方法对多方都有用，我们将在整篇文章中更详细地描述这一点。工具开发人员可以使用我们的技术来优化他们的工具，并决定哪些技术和语言需要更好地支持。产品经理可以使用我们的技术进行基础且低成本的市场分析。Stack Overflow 团队本身可以利用我们的结果来更好地管理他们的网站。我们的方法还可以扩展，以帮助自动生成帖子的上下文标签，使用户能够更直观地搜索和归档文本内容。此外，我们的技术还可以用来定位内容相似的帖子，以便用户可以阅读与其问题相关的所有问题和答案。

同的

本文其余部分安排如下。我们在第二部分介绍研究问题、研究数据和研究方法。第三部分展示研究问题的结果。第四部分在更广泛的背景下讨论研究结果。第五部分讨论了对效度的潜在威胁。第六部分概述了相关工作。最后，第七部分总结并展望了未来的工作方向。

2 研究背景

在本节中，我们将详细介绍我们的研究背景。首先，我们提出四个研究问题并阐明研究动机。然后，我们将描述用于解答研究问题的研究数据。最后，我们将介绍我们的研究方法，包括用于分析研究数据的指标。

2.1 研究问题

RQ1. Stack Overflow 中主要讨论的主题有哪些？

现代开发人员在多个平台上工作，拥有丰富的编程语言选择，并使用不同的工具和技术来满足他们的需求。编程问答网站旨在满足面临挑战的开发人员的需求。识别此类知识共享平台中的主要讨论主题可以帮助我们找到开发人员感兴趣的主要领域。这些信息可以帮助公司优化其产品的各个方面，例如API、产品文档和支持工具的设计。这些信息还可以帮助技术书籍的出版商，因为它指出了从业者最感兴趣和最有疑问的领域。此外，这些信息还为软件工程研究人员提供了一些棘手领域的第一手资料，这些领域可能是未来的研究领域，并且很有可能对实践产生影响。主要讨论主题还可以突出最流行的编程语言、工具和技术。

RQ2. 一个主题中的问题是否会引发另一个主题中的答案？

我们还会调查某些主题在问题和答案方面是否与其他主题相关。这可以帮助我们识别紧密耦合主题，其中

同一主题的问题往往会在看似不相关的主题中产生答案。此外，这还能帮助指出不同主题的开发者的交叉领域：这些问题非常普遍，以至于跨越多个领域。例如，如果许多关于移动应用程序开发和 Web 开发的问题都产生了与用户界面相关的答案，这暗示着用户界面开发是跨两个不同平台的开发者所面临的交叉关注点。

RQ3. 开发人员的兴趣如何随时间变化？

通过分析不同主题用户兴趣的起伏，产品开发者能够评估其产品的相对受欢迎程度。这也有助于识别市场营销和研究机会及趋势。例如，如果用户对……感兴趣。NET 框架话题正在兴起，而人们对此的兴趣 Java 如果话题热度下降，那么公司、图书出版商和研究人员可能需要关注.NET 的问题和挑战。趋势分析也有助于推断开发者讨论中某些主题的兴衰。

RQ4. 对特定技术的兴趣如何随时间变化？

虽然调查主题影响力随时间的变化可以洞察开发者思维的总体趋势，但我们也关注特定技术的趋势，以及人们对相关/竞争技术的兴趣随时间的变化。例如，我们希望直接比较两种脚本语言 Perl 和 Python 的流行度。这不仅让我们更集中地了解某些产品，还能让我们比较某项技术在多个主题中的影响。

2.2 研究数据

Stack Overflow (2012a) 是一个在线平台，用户可以在此交流与编程和软件工程任务相关的知识。该网站允许用户提出新问题和回答现有问题，并根据帖子的感知价值对问题和答案进行“投票”。Stack Overflow 的用户可以通过各种活动获得声誉点数和“徽章”。例如，任何答案获得“赞同”票即可获得 10 点声誉点数，获得 300 次投票即可获得一枚徽章。

Stack Overflow 根据知识共享许可 (Stack Overflow 2012b) 以 XML 格式公开其数据。数据集分为五个 XML 文档：徽章.xml、评论.xml、帖子.xml、用户.xml 和投票.xml。为了我们的目的，我们使用 posts.xml，其中包含帖子的实际文本内容，以及浏览次数、收藏次数、帖子类型、创建日期和创建每个帖子的用户的 ID。

我们的 Stack Overflow 数据集涵盖了 27 个月的时间，从 2008 年 7 月到 2010 年 9 月。经过预处理（详见第 2.3.2 节）后，帖子长度在 1 到 3,844 字之间。大多数帖子（99.7%）少于 500 字。2008 年 7 月，Stack Overflow 只有 7 篇帖子。这是因为当时只有一天（7 月 31 日）的讨论。




图 1 我们的 Stack Overflow 数据集中每月的新帖子数量。

数据集。相比之下，2010 年 9 月有 206,371 个帖子。每月帖子数量如图 1 所示。总的来说，我们的数据集包含 3,474,987 个帖子，其中 973,267 个（28%）是问题，2,501,720 个（72%）是答案。

2.3 研究方法

正如我们在研究问题中所述，我们的研究目标是找到 Stack Overflow 中的主要讨论主题。Stack Overflow 目前将每个问题按用户定义的标签我们曾考虑将其作为衡量主要讨论主题的起点。然而，这些标签存在一些缺陷，使其无法服务于我们的研究目标。

首先，标签并非预先定义，而是由用户在发布问题时自行添加，这可能导致标签错误且不一致。例如，一个用户可能使用标签“iphone api”，而另一个用户可能使用“iphone sdk”。尽管意图相同（即帖子相关），但这些帖子的标签各不相同，无法归为一组。事实上，这个问题导致了“标签爆炸”（图2），因为标签数量每月都在快速增长（平均每月新增1097个标签），但只有一小部分（4%）用于对大多数（90%）的问题进行分类。此外，由于标签只能应用于问题帖子，而不能应用于答案帖子，因此很多文本内容都未添加标签。此外，标签除了提供问题帖子的总体信息外，可能无法提供任何其他信息。例如，一个标签为“C#”的问题只能告诉我们该问题与C#语言有某种关联，而无法告诉我们它是GUI开发问题还是网络相关问题。这些缺点促使我们评估一种不同的方法来发现 Stack Overflow 中的讨论主题。

在本文中，我们使用主题建模发现 Stack Overflow 帖子的讨论主题。主题图来自这建模是一种先进的信息技术，可以自动找到最重要的主题从不需要佛 r 标 等瓦尔特ch-签、训练数据或预定义税 2007; Blei 和 L erty 2009)。主题建模仅绘用英文特西特公用我扮演在喻 IE秒格里这 e塔尔他 喔路 法语 英国际 nd




图2Stack Overflow 中用户生成标签的特点。(a) 每个月都会创建许多新标签。(b) 唯一标签的数量随着时间的推移持续增长。




图3我们的研究方法概述。

文档本身的共现频率来构建相关词汇的模型。使用这种方法，主题建模已成功应用于其他领域，用于自动组织和分析数百万个非结构化文档。

文献，例如分析科学文献趋势 (Griffiths and S 2004)、研究软件系统的演变 泰弗斯 (Linstead et al 2008; et al 2011)，甚至计算机视觉 (Barnard et al 2003)。托马斯

我们的研究方法基于主题建模，使用 dis 主题作为我们感兴趣的讨论主题的 覆盖近似值。该方法包含以下步骤 (见图 3)。首先，我们对 Stack Overflow 数据集中的帖子进行预处理。其次，我们将建模技术应用于提取和预处理的帖子。最后，我们

发现 关于主题，通过定义其使用指标并检查 e，现在更详细地讨论每个步骤。随着时间的推移。

2.3.1 数据提取

提取 来自 Stack Overflow 数据集的帖子，我们从帖子.xml Stack Overflow 数据集中提取，包含所有用户帖子（即问题、答案、评论）在 Stack Overflow 上。我们将每个帖子分成各自的 document，总共创建了 3,474,967 个文档。

在对问题的分析中，我们考虑了几个答案帖子的原因。首先，回答帖子包括数据集中 72% 的帖子，即 2,500,000 个。其次，我们希望分析的大多数文本内容位于 posts。其次，我们的研究问题之一是在 answers 页面发现

<pre>我一直无法让 C 套接字 API 在 C++ 中正常工作。具体来说，尽管我包含了 sys/socket.h 文件，但仍然出现编译时错误，提示 AF_INET 未定义。我是不是忽略了某些显而易见的问题，还是因为我在 z/OS 上编写代码，导致问题更加复杂？</pre>

(a) 预处理之前。

问题 c 套接字 api 工作正常 c++ 具体包括 sy socket.h 编译时错误 af inet 定义错过明显关系事实代码 z os 问题复杂

(b) 预处理后。

图 4 (a) Stack Overflow 数据集中的一篇示例帖子 (posts.xml)。(b) 预处理步骤删除 HTML 标签、删除停用词，并对每个单词应用词干提取算法。

问题主题和答案主题之间的关系；我们必须包括答案帖子来发现这些关系。

对于每个提取的帖子，我们都会保留其元数据的记录，其中包括时间戳、帖子类型（即问题或答案）、用户指定的标签，以及对于答案帖子，指向它正在回答的问题的指针和对于问题帖子，指向其所有答案的指针。

2.3.2 数据预处理

我们分四步清理提取的帖子的文本内容。首先，我们丢弃帖子中存在的任何代码片段（例如，<code>HTML 标签），因为源代码语法（例如，如果声明和为了循环）会在分析阶段引入噪音。由于所有代码片段都包含类似的编程语言语法和关键字，因此这些代码片段不利于主题模型找到有用的主题 (Thomas 2012b)。此外，由于 Stack Overflow 上的大多数源代码仅以小片段的形式显示，因此缺乏足够的上下文来从片段中提取有意义的内容 (Kuhn et al 2007)。接下来，我们删除所有 HTML 标签（例如，和 ），因为这些不是我们分析的重点。第三，我们删除了常见的英语停用词，例如“a”、“the”和“is”，因为它们无助于创建有意义的主题 (Manning et al 2008)。最后，我们应用 Porter 词干提取算法 (Porter 1997)，该算法将单词映射到它们的基本形式（例如，“programming”和“programmer”都映射到“program”）。图 4 展示了预处理前后的示例帖子。我们在线提供了提取和预处理的数据集 (Thomas 2012a)。

2.3.3 主题建模

研究人员已经开发了许多主题建模技术来解释不同的数据类型、假设和目标。在本文中，我们使用一种流行的主题建模技术，称为潜在狄利克雷分配 (我们选择使用 LDA (线性判别分析) 来解决这个问题，因为它最适合我们的研究目标，即在自然语言文本文档中寻找讨论主题 (Blei 等人，2003 年))。

LDA 是一个统计主题建模技术，这意味着 LDA 将主题表示为语料库中单词的概率分布，将文档表示为已发现主题的概率分布。LDA

当它在语料库的文档中找到一组倾向于频繁共现的词时，它就会创建主题。通常，所发现主题中的词在语义上是相关的，这赋予了整个主题以意义。例如，某个主题中出现概率最高的词可能是“行星”、“太空”、“恒星”和“轨道”（因为这些词在文档中倾向于一起出现），这表明该主题与天文学相关。此外，LDA 可能会告诉我们某个文档既包含与天文学相关的主题，也包含与数学相关的主题。因此，现在可以轻松收集所有与天文学、数学或两者相关的文档，而无需使用任何训练数据或手动创建的标签。

LDA 实现。LDA 本质上是概率性的。给定一组文档，LDA 使用机器学习算法推断每个文档的主题及其主题成员关系。在本文中，我们使用 MALLET 2.0.6 版本 (McCallum 2002) 提供的 LDA 模型实现，该版本是吉布斯采样算法 (Geman 和 Geman 1984) 的一种实现。我们对 MALLET 进行了 500 次吉布斯采样迭代，之后吉布斯采样算法已经稳定下来 (Griffiths 和 Steyvers 2004)。

主题数量。主题数量，表示为 k 是用户指定的参数，用于控制发现主题的粒度。较大的 k 将产生更细粒度、更详细的主题，而较小的值 k 会产生更粗粒度、更一般的主题。没有单一的值 k 这适用于所有情况和所有数据集 (Wallach 等人, 2009; Grant 和 Cordy, 2010)。在本文中，我们的目标是中等粒度的主题，以便这些主题能够捕捉数据集的总体趋势，同时又能保持彼此之间的差异。在对各种值进行实验后，我们设定 k 到 40，这提供了我们想要的特性。

二元语法。LDA 可以对 uni-gram (即单个单词) 或 n -grams (即 n 数据集中有三个相邻单词。例如，给定文本“编译时错误”，有三个单元语法 ({“编译”、“时间”、“错误”}) 和两个 2-gram ({“编译时”、“时间错误”})。由于 2-gram (等效地，二元语法) 已被证明可以提高文本分析的质量 (Tan et al 2002)，我们在创建主题时同时使用了单元语法和二元语法。(我们通过传递 --克重 1,2 选项为 MALLET。

LDA 的输出。将 LDA 应用于我们的预处理数据的结果是 (a) 一组主题，定义为数据集中唯一单词的分布，以及 (b) 一组主题成员向量，每个帖子一个，表示帖子中来自每个帖子的单词的百分比主题。如前所述，主题中出现概率最高的词汇在语义上相关，它们共同揭示了主题的性质或概念。为了便于阅读，我们还为每个主题手动提供了一个简短的标签，例如，为包含“查询”、“表”、“sql”和“行”等热门词汇的主题添加“SQL”标签。我们根据主题中的热门词汇以及包含这些主题的帖子样本来选择标签。我们还注意到，最近已经提出了为主题分配标签的自动化方法 (Mei et al 2007)。

2.3.4 指标与分析

LDA发现主题, $z_1, \dots, z_K$ 。我们表示特定话题 z_k 在文档 d 中作为 $\theta(d, z_k)$ 。我们注意到 $\forall d, k: 0 \leq \theta(d, z_k) \leq 1$ 和 $\sum_k \theta(d, z_k) = 1$ 。使用这种符号, 我们计算以下指标

兴趣来帮助回答我们的研究问题。

我们首先定义一个阈值, δ , 用于指示特定主题是否“在”文档中。通常, 一篇文档会有1到5个主要主题, 每个主题的隶属度为0.10或更高(Blei等人, 2003)。这些主题构成了文档中的主要主题。然而, 由于LDA的概率特性, 有时主题会被分配到文档中较小但不为零(例如0.01)的隶属度, 并且与我们的分析无关。因此, 通过使用 δ 阈值作为成员截止值, 我们只保留每个文档中的主要主题, 并丢弃概率错误。在本文中, 我们设置 δ 到0.10, 我们发现这可以消除嘈杂的主题成员资格, 同时仍然允许每个文档中只出现主导主题。



主题分享 (RQ1)。我们定义整体分享一个主题 z_k 在所有帖子中

$$\text{分享}(z_k) = \frac{1}{|D|} \sum_{\substack{d \in D \\ \theta(d, z_k) \geq \delta}} \theta(d, z_k) \quad (1)$$

在哪里 D 是我们数据集中所有帖子的集合。分享指标衡量的是包含该主题的帖子的比例 z_k 。例如, 如果某个主题分享率为10%, 则表示所有帖子中有10%包含该主题。分享率指标使我们能够衡量该主题在所有帖子中的相对受欢迎程度。

主题关系 (RQ2)。我们希望确定问题中的主题与相应答案中的主题之间是否存在关系。我们将讨论定义为单个问题帖及其答案帖。我们定义关系相对在一次讨论中两个主题之间 $z_{\text{问}}$ 和 $z_{\text{一个}}$ 作为

$$\text{相对}(z_{\text{问}}, z_{\text{一个}}) = \frac{1}{\sum_{\substack{d_{\text{问}} \in Q, d_{\text{一个}} \in \text{一个}(d_{\text{问}}) \\ \theta(d_{\text{问}}, z_{\text{问}}) \geq \delta, \theta(d_{\text{一个}}, z_{\text{一个}}) \geq \delta}} \theta(d_{\text{问}}, z_{\text{问}}) \times \theta(d_{\text{一个}}, z_{\text{一个}})} \quad (2)$$

在哪里 Q 是所有问题帖子的集合, $\text{一个}(d_{\text{问}})$ 是与问题相关的所有答案的集合 $d_{\text{一个}}$ 。然后, 我们将所有讨论汇总起来, 生成汇总相对每个答案主题相对于特定问题主题的价值。我们使用加权指标来量化发散的回答主题, 即问题中未提及的主题。例如, 如果 $\theta(d_{\text{问}}, z_k) = 0$, 一个问题 $d_{\text{问}}$ 和 $\theta(d_{\text{一个}}, z_k) = 0.1$ 为答案 $d_{\text{一个}}$ 对于这个问题, 那么相对较小的度量值0.08表示 $d_{\text{一个}}$ 与主流话题不同 z_k 的 $d_{\text{问}}$ 。

随时间变化的主题趋势 (RQ3)。我们还希望分析主题的时间趋势。为此, 我们定义了影响一个主题 z_k 在一个月 m 内米作为

$$\text{影响}(z_k, m) = \frac{1}{|D(m)|} \sum_{d \in D(m)} \theta(d, z_k) \quad (3)$$

在哪里 $D(m)$ 是本月所有帖子的集合。这影响该指标衡量的是该主题相关的帖子相对于该特定月份其他主题的相对比例。

随时间变化的技术趋势 (RQ4)。我们希望比较和对比相关技术的趋势, 例如 Android 与 iPhone, 或 C# 与 Java。我们的主题建模方法创建了 $m=40$ 个主题, 这些主题与我们之前的研究问题相符, 但过于宽泛, 无法进行如此细致的分析。此外, 用户创建的标签对于本次分析来说过于详细 (例如, iPhone 技术就有很多标签, 例如 “iphone-sdk-3.2” 和 “iphone-3gs”), 此外, 还存在 2.3 节中列出的局限性。我们提出了一种结合主题模型和用户创建标签的分析技术, 该技术克服了上述局限性, 同时使我们能够研究技术趋势。

我们定义一个技术组与特定技术概念 (例如 iPhone) 相关的标签, 这些标签都与给定主题 (例如移动应用相关主题) 相关。为了识别一项技术, c , 与主题相关 z_k , 我们手动选择与技术相关的最热门标签组 c 并且与主题相关 z_k 。例如, 对于 iPhone 技术, 我们从移动应用相关主题中选择了 “iphone-sdk-3.2”、“iphone-3gs”、“iphoneapp”、“iphone-sdk-documentation”、“iphone”、“iphone-os-4.0” 和 “cocos2d-iphone” 等标签。与简单地统计与标签相关的帖子相比, 我们的方法有两个主要优势。首先, 我们的方法有助于消除由标签不当的帖子引起的噪音, 因为我们只考虑标签恰当的帖子和实际上包含了感兴趣的主题。其次, 它提供了更准确的趋势描述, 因为我们只考虑与某个主题相关的帖子的比例, 而不是整个帖子 (部分与给定标签相关的帖子可能会造成整体偏差)。

具体来说, 我们首先识别与给定主题相关的所有标签。我们称一个标签 c 与主题相关 z_k 如果标签分数 $(g, z_k) > 0$, 其中

$$\text{标签分数}(g, z_k) = \sum_{d \in D(g)} \theta(d, z_k) \quad (4)$$

在哪里 $D(g)$ 是一组带有标签的帖子 g 。

接下来, 我们会直观地选择与特定技术相关的标签。例如, 对于 iPhone 技术, 我们会对所有包含以下关键词的标签进行文本搜索: 例如 “iphone”、“cocoa” (iPhone 的 UI 框架) 等。

最后, 每个月 m , 有问题 $q(m)$, 我们定义技术影响一项技术 c 作为:

$$\text{技术影响}(c, z_k, m) = \sum_{d \in \text{格}(c, z_k, m)} \theta(d, z_k) \div \sum_{d \in \text{问}(m)} \theta(d, z_k) \quad (5)$$

在哪里 $\text{格}(c, z_k, m)$ 表示所有与技术相关的标签 c 根据主题 z_k 在一个月 m 此指标衡量的是某项技术在一个月内相对于该月所有讨论的讨论量。请注意, 此分析仅限于问题帖, 因为 Stack Overflow 只允许对问题帖进行标记。我们的方法凸显了 Stack Overflow 数据集中用户创建标签的缺点。在这里, 我们量化了语境

价值通过使用LDA分配的标签成员值来识别标签，这是单靠标签无法实现的。换句话说，如果用户错误地将“Java”问题标记为“C#”，那么我们的主题建模方法会自动为该标签分配一个较低的值。在上下文中这篇文章的标签。这样，我们可以最大限度地减少错误标签造成的噪音。此外，它还能让我们看到一项技术在不同主题中的影响。

3 结果

现在，我们将展示将我们的研究方法应用于研究数据集的结果。本节的重点是简洁地回答每个研究问题。在第四部分，我们将在更广泛的背景下总结和讨论这些结果。

3.1 RQ1. Stack Overflow 中主要讨论哪些主题？

我们在表 1 和表 2（附录 A）中展示了我们的方法从 Stack Overflow 中发现的 40 个主题。这些主题按其重要性降序排列。分享指标（公式 1）。对于每个主题，我们还展示了问题帖子的比例和答案帖子的比例。为了更好地理解这些主题，我们提供了部分主题以及每个主题的代表性示例帖子。

与网络相关的讨论。在 40 个主题中，有三个主题专门与网络有关，分别是：网站设计/CSS、Web 开发、和 Web 服务/应用程序。这些主题的一些示例帖子如下：

我想给表格中最后一个 td 添加样式，但又不想在该 td 上使用 CSS 类。我希望包含文本“5”的 td 没有边框，但又不想使用 CSS 类。

主题：网站设计/CSS：0.92

我们知道 JavaScript 框架有很多，比如 Dojo 等等。哪个最适合与 ASP.NET 一起使用？

主题：Web 开发：1.0

只需使用添加服务引用并将其指向 wsdl 即可。了解如何使用 Web 服务。

主题：Web 服务/应用程序：1.0

（在这些示例中，我们显示原始帖子内容，然后是帖子包含的主题的名称和成员资格。）

数据管理。我们在 Stack Overflow 上找到了多个数据管理主题，包括数据库平台、SQL、XML、和对象关系映射。数据库平台-具体的帖子包含与底层平台（如 MySQL（2012）和 SQL Server（2012））相关的更多具体问题，而不是 SQL 主题，重点介绍查询和存储过程等一般概念。XML 数据格式的广泛使用可以从整个 XML 主题。以下示例帖子来自数据库平台、SQL、和 XML 主题分别为：

我想在 SQL Server 中创建一个表，并在插入时添加一个自增主键。这应该是一个类似 MySQL 的自增 ID。

主题：数据库平台：0.91

下面是我的存储过程。我想用存储过程从表成员中选择所有日期行并插入表，但不起作用。有人能帮帮我吗？

主题：SQL：1.0

您好，我需要根据 DTD 模式验证一个 XML 文件。我发现我需要传递模式文件的源文件进行验证。请问 libxml2 能找到 XML 文件中的模式声明并自行进行验证吗？还是我必须手动检索声明？提前谢谢！

主题：XML：0.98

特定平台的讨论。我们找到了与开发和部署平台相关的讨论。开发平台是指开发人员用来构建产品的工具、IDE 和语言，例如 Visual Studio (2012) 和 Java (2012)。为此，我们找到了诸如……之类主题。NET 框架、Java、和 Windows/Visual Studio。部署平台是指开发软件部署的目标环境或硬件（例如 Windows、移动设备等）。为此，我们找到了移动应用程序开发主题和 Web 相关主题（网站设计/CSS、Web 开发、和 Web 服务/应用程序）。请注意 Windows/Visual Studio 主题也代表了 Windows 部署平台。下面我们将展示这些主题的一些示例帖子。

我已经安装了 Visual Studio Professional。如果我为手机安装 Visual Studio Express，Visual Studio 还能正常工作吗？

主题：Windows/Visual Studio：0.95

将 Web 应用程序从 .Net 1.1 升级到 .Net 3.5 有哪些令人信服的理由？

主题：。NET 框架：0.87，Web 服务/应用程序：0.13

jdk 和 java sdk 没什么区别。它们的意思是一样的。我觉得 SUN 的公关部门决定把 jdk 改成 java sdk。

主题：Java：0.84，编码风格/实践：0.11

Android SDK 包含一个模拟器。你的应用会因此失败吗？主题：移动应用程序开发：0.89，错误/异常：0.11

安全。我们发现两个与软件产品的安全功能相关的不同主题：身份验证/安全和密码学。这些主题的两个示例帖子是：

如果用户通过 openid 登录，是否可以获取名称 id 等登录凭据？主题：身份验证/安全：1.0

使用强大的加密哈希函数，例如 md5 或 sha1，但务必使用合适的盐值。否则，您将容易受到彩虹表攻击。

主题：密码学：0.94

质量保证和协作。在产品开发过程中，版本控制（例如 Apache SVN（2012）或 Git（2012））通常用于促进协作并提供源代码的历史跟踪。在这方面，我们发现版本控制主题。开发软件产品后，诸如测试之类的后期开发任务对于质量保证至关重要。在这里，我们发现 **测试主题**。示例帖子如下：

我有一个包含多个分支的 Git 仓库。如何知道哪些分支已经合并到主分支？

主题：版本控制：1.0

我想知道如何对旧的 ASP 页面进行性能测试。您用过什么工具吗？

主题：测试：0.83，.NET 框架：0.17

知识/经验。我们在 Stack Overflow 上找到了两个主题，它们代表了程序员关于知识和经验分享的讨论。第一个主题是工作/经验主题，程序员讨论其工作场所遵循的特定流程和实践，以及与编程相关的其他经验，例如以下问题：

你未来几年还会继续编程吗？你认识的最年长的开发者是谁？

主题：工作/经验：1.0

第二个这样的主题是学习主题。该主题主要包含有关学习语言、技术或算法的问题，如下例所示：

我想设计一个网站，但不知道从哪里开始。有没有入门指南可以参考？

主题：学习：1.0

一般性讨论。分享量排名前三的话题是编码风格/实践，问题/解决方案，和质量保证和链接主题。这三个主题都是通用的英语主题，不属于任何技术类别。例如，请考虑以下帖子：

你的算法可读性强吗？或许，将其拆分成几个函数，即使不能减少重复，也能提高可读性和可维护性。

主题：编码风格/实践：0.81，性能/优化：0.19

我在谷歌搜索的时候发现了这个链接。它可能就是你要找的。主题：质量保证和链接：1.0

我相信类似这样的方法可以解决你的问题。主题：问题/解决方案：1.0

这些主题占比较高的原因是 Stack Overflow 帖子的自然语言对话风格。由于许多帖子包含日常生活中使用的通用词汇，LDA 模型预计能够发现此类主题。然而，这些主题并非我们分析的重点，因此在后续分析中我们不会重点介绍这些主题的示例。

回答主题	分数	回答主题	分数
Web 开发	12019.7	网站设计/CSS	19035.5
UI 开发	3306.6	Web 开发	3295.6
网站设计/CSS	3133.1	图像/显示	2408.6
功能	2283.2	UI 开发	2157.6
代码片段	1901.6	文本相关	2038.3
(一个) Web 开发		(二) 网站设计/CSS	
回答主题	分数	回答主题	分数
移动应用程序开发	10008.3	UI 开发	16879.2
工作/经验	1700.5	Web 开发	3475.4
UI 开发	1610.8	面向对象编程	3051.4
图像/显示	1541.4	网站设计/CSS	2572.8
文件操作	1384.0	图像/显示	2488.9
(三) 移动应用程序开发		(四) UI 开发	
回答主题	分数	回答主题	分数
测试	3888.3	版本控制	8786.9
面向对象编程	919.6	文件操作	1465.4
工作/经验	887.7	项目/开源	1033.3
项目/开源	543.4	工作/经验	940.2
功能	505.9	联网	484.1
(e) 测试		(六) 版本控制	
回答主题	分数	回答主题	分数
身份验证/安全	10811.4	数据库平台	15110.4
联网	2516.7	SQL	5037.6
工作/经验	1638.1	对象关系映射	2099.9
Web 开发	1578.5	性能/优化	2055.3
数据库平台	1446.5	工作/经验	1554.3
(克) 身份验证/安全		(八) 数据库平台	
回答主题	分数	回答主题	分数
工作/经验	28081.7	学习	19429.8
学习	6620.1	工作/经验	7168.4
项目/开源	3247.4	编译	2908.9
性能/优化	2411.8	功能	2766.3
.NET框架	1955.5	性能/优化	2193.5
(我) 工作/经验		(j) 学习	

图5选定的问题主题和前五个触发的答案主题，按其排序 相对指标得分（公式 2）。对于每个答案主题，总相对报告与该问题主题相关的所有回答帖子的得分。

3.2 RQ2. 一个主题中的问题是否会引发另一个主题中的答案？

我们的第一个研究问题是发现 Stack Overflow 用户之间的讨论主题。虽然结果让我们大致了解了这些讨论主题，但我们也希望发现它们之间的关系和相互依赖性。

在不同主题之间进行研究。这可以帮助我们将紧密耦合的主题组合在一起：这些主题表面上彼此不同，但一个主题中的问题有可能引出属于另一个主题的答案。这种分析可以帮助我们识别跨多个主题领域的开发人员面临的共同问题。它还指出了单个主题的多样性：一个主题将来自多个主题的知识和资源汇集在一起，并有能力在其他主题中生成答案。

我们使用 *相对* 指标（公式 2）来确定主题对之间的关系。图 5 突出显示了一些更有趣的关系。对于每个问题主题，我们列出五个最相关的答案主题，并根据其相关性按降序排列。*相对* 指标得分。对于所有问题主题，答案比例最高的是问题主题本身。然而，更有趣的发现是剩下的四个答案主题。

例如，从图 5(a)、5(b) 和 5(c) 可以清楚地看出，用户界面相关问题比 Web 和移动应用程序开发中的其他问题更为紧迫，因为这三个问题主题的前五个答案主题（Web 开发、网站设计/CSS、移动应用程序开发）包含 UI 开发 主题。请考虑以下示例。

问题：我的应用程序中有一个活动，当我调用行 `EditText username = (EditText)findViewById(R.id.usernameText);` 时，应用程序崩溃，这是为什么？

主题：移动应用程序开发：0.89，面向对象编程：0.11

回答：视图尚未膨胀，或者缺少 `setContentView(R.layout.layout 文件)`

主题：UI 开发：1.0

问题：我的 `asp.net webform` 中有一个提交按钮和一个返回按钮。我本应该在按 `Enter` 键时使用提交按钮，但它却跳转到了返回按钮。请帮忙……

主题：Web 开发：0.85，问题/解决方案：0.15

回答：将您的部分包装在面板中 - 然后您可以使用 `DefaultButton` 属性将提交按钮设置为按下输入键时的默认按钮。

主题：UI 开发：0.77，Web 开发：0.23

在第一个问答中，提问者想确定他的应用程序崩溃的原因。一位开发人员在回复中指出，崩溃确实是由于缺少对 UI API 的调用造成的。在第二个问题中，提问者对他的 ASP.NET Web 应用程序在输入“Enter”键时的行为感到困惑。作为回应，回答者展示了一种 UI 小部件（例如“控制板”）可以用来解决这个问题。这表明开发人员在开发软件时可能没有意识到某些 UI API。我们在图 5(a)、5(b) 和 5(c) 中的发现表明，这种情况在 Stack Overflow 用户中很常见。此外，这个问题分布在两个完全独立的开发平台上：移动设备和 Web。

这 UI 开发主题本身会生成答案面向对象编程主题，指出了面向对象哲学和设计模式在构建用户界面小部件（Gamma 等人，1995）中的应用。这可能是因为许多 UI 小部件（例如按钮、菜单和组合框）都是以类库的形式实现的。通常，程序员必须使用从

这些类库来实现所需的小部件，如下例所示。

问题：大家好，我想使用一个 `UIView` 和一个 `UIImage`，并在其上放置一个文本框和按钮，我希望用户在触摸 `UIView` 或视图中的任何内容时拖动它，实现此方法的最佳方法是什么？
`UIView` 位于单个视图控制器上，并使用 `Interface Builder` 来制作我的 `UIView` 和 `UIImage`。

主题：UI开发：0.84，图像/显示：0.13

回答：您需要将 `UIView` 子类化并实现

- `(void) touchesBegan: (NSSet *) touches withEvent: (UIEvent *) event` 事件，
- `(void) touchesMoved: (NSSet *) touches withEvent: (UIEvent *) event` 事件，
- `(void) touchesEnded: (NSSet *) touches withEvent: (UIEvent *) event`，以及
- `(void) touchesCancelled: (NSSet *) touches withEvent: (UIEvent *) event` 事件。

主题：面向对象编程：1.0

另一个有趣的发现是移动应用程序开发主题在工作/经验主题（图 5(c)），表明移动设备正在崛起，成为开发者利润丰厚的部署平台。请考虑以下示例。

问题：我如何通过开发免费向公众开放的应用程序获得报酬？主题：移动应用程序开发：1.0

回答：通常情况下，除非你的项目规模足够大，能够吸引大量用户，否则你不会这样做。之后，你可以通过广告（在你的网站或产品中）或大公司购买项目（例如 `Qt` / `Novell`）来获得收入。但通常来说，免费软件是免费的。如果你足够优秀，人们认可你，你或许能找到工作，但如果你的软件没有真正独特的创意，用户很可能会选择没有广告的替代方案。利用免费软件获利并非不可能，但绝非易事。此外，你可以为你的项目开放捐赠，但通常捐赠的条件是，捐赠必须用于改进产品。

主题：工作/经验：0.74，项目/开源：0.24

这里，一位开发者想知道如何通过免费移动应用创收。另一位开发者根据自己的经验，概述了一种方案。值得注意的是，这位开发者还暗示了工作机会。

现代软件开发流程中不可或缺的两个组成部分是测试和版本控制 (Pressman 2005; OSS Watch 2012)。从图 5(e) 和 5(f) 可以看出，这两个问题主题 (测试、版本控制) 在项目/开源主题，这是这些阶段开源工具使用情况的一个指标。此外，开源项目本身也依赖于版本控制系统。答案通常包括回答者工作场所的版本控制实践，解释了工作/经验回答中的主题版本控制问题。大多数版本控制系统处理文件，并通过网络分布，这解释了文件操作和联网答案中的主题。以下两个示例说明了开源工具的使用以及测试和版本控制方面的经验分享。

问题：是否可以使用谷歌测试框架通过测试获得代码覆盖率？

主题：测试：0.85，质量保证和链接：0.15

回答：是的，我成功使用了免费工具 (gcov) 和商业工具 (CTC++)。无需特殊步骤，只需按照文档操作即可。

主题：项目/开源：1.0

问题：使用 Subversion 时，开发人员是否应该在主干上工作，或者主干是否应该仅用于每个开发人员的分支的合并并由持续集成服务监视？

主题：版本控制：0.91

回答：我几乎一直在主干上开发的团队工作——效果很好。我不是说这是最好的主意，只是如果反对它会让你被解雇，那就不值得。然而，我们的系统始终是可构建的，并且经常使用持续集成 (CI)。每个开发人员都必须了解更新/重建/重新测试/提交的周期。

(虽然不是万无一失，但效果已经足够好了。) 唉，想到我们有多少软件实践“足够好”，我就感到很难过。

主题：工作/经验：0.75，问题/解决方案：0.17

身份验证/安全是一个多元化的主题，在计算机科学的许多领域都有应用。从图 5(g) 中我们可以看到，与身份验证/安全是网络、Web 开发、工作/经验和数据库平台。随着 SQL 注入和跨站脚本 (XSS) 等攻击的频率和严重程度不断上升，跨领域经验丰富的安全专家的需求日益凸显 (Neuhaus and Zimmermann 2010)。以下示例说明了 Stack Overflow 开发人员对安全漏洞的担忧以及对合格人员的需求。

问题：我认识几个遇到过类似情况的人。假设你正在随机测试一些网站，寻找基本的 XSS/SQL 注入漏洞，结果发现其中一个网站很容易被攻破。你给管理员/网站管理员发了邮件，但他们没有回复。你会怎么做？

主题：身份验证/安全：0.81，编码风格/实践：0.15

回答：我通常会想办法联系开发人员或 QA 人员，然后告诉他们。如果你活跃在开发者社区，这更容易做到。有时管理员/网站管理员/其他人员实际上是服务台/市场营销人员，他们对漏洞知之甚少或一无所知，或者工作繁忙，以至于没有意识到此类漏洞的严重性。

主题：工作/经验：0.84

这数据库平台主题包含来自 SQL 主题 (图 5(h))。更有趣的是，我们还看到对象关系映射主题与数据库平台主题，这是面向对象数据库日益流行的标志。我们还可以看到数据库平台给出了答案性能/优化主题。这一结果可能是由于查询处理性能对现代数据密集型应用程序的效率影响巨大。例如，考虑以下关于数据库性能的问答：

问题：MySQL 有一个特殊的表类型 MyISAM，它不支持事务。Oracle 有类似的吗？我想创建一个只写数据库 (用于日志记录)，它需要非常快 (将存储大量数据) 并且不需要事务。

主题：数据库平台：0.89，性能/优化：0.11

回答：如果您需要极高的性能，另一个选择是考虑 Oracle 的 TimesTen 内存数据库：

<http://www.oracle.com/technology/products/timesten/index.html>

主题：性能/优化：0.65，数据库平台：0.35

上述大多数问题主题（移动应用程序开发、测试、版本控制、身份验证/安全、数据库平台特色答案工作/经验主题（图 5(c)、5(e)、5(f)、5(g) 和 5(h)）。事实上，工作/经验相关帖子本身也属于同一个主题（见图 5(i)）。我们看到性能/优化作为另一个与工作/经验，这实际上可能指的是开发人员谈论他们在工作中的表现的帖子。有趣的是，我们看到项目/开源和 .NET 框架，这表明业界使用的开源工具和商业工具种类繁多。我们还发现工作/经验问题产生答案学习主题，暗示软件工程师的学习过程即使在正规教育之后仍会继续，如下例所示：

问题：如果您可以回到过去，并在编程生活/职业生涯开始时给自己一条建议来帮助您，那会是什么？

主题：工作/经验：1.0

回答：学习 Smalltalk。越早真正欣赏和理解面向对象设计越好！

主题：学习：1.0

我们注意到反之亦然：学习问题产生答案工作/经验主题（图 5(j)）。造成这种关系的原因之一可能是新手开发人员提出的问题得到了相对经验丰富的开发人员的回答，这些开发人员分享了他们的工作经验和实践见解：

问题：我在这里看到很多关于函数式语言之类的讨论。为什么要用函数式语言而不是“传统”语言呢？它们有哪些优势？又有哪些劣势？理想的函数式编程应用是什么样的？

主题：学习：0.80，功能：0.15

回答：我认为，既然微软已经将其进一步推向主流，它就会流行起来。对我来说，它之所以有吸引力，是因为它能为我们带来很多好处，因为它是一个新挑战，也因为它能带来就业机会。未来。一旦掌握，它将成为另一个工具，进一步帮助我们提高程序员的生产力。

主题：工作/经验：0.95

该示例突出了 Stack Overflow 的知识共享特性。

3.3 RQ3. 开发人员的兴趣如何随时间变化？

计算机科学是一个快速变化的领域，受创新和消费者需求的驱动。软件开发者需要关注工具和技术的最新进展，否则可能会面临日后追赶的风险。因此，我们预计开发者讨论趋势将与市场趋势共生。表 2




图6 Stack Overflow 中排名前五的上升和下降趋势，以 2008 年 8 月至 2010 年 9 月期间影响力的百分比变化来衡量。




图7 主题的比较趋势分析。某个主题对特定月份的影响是通过以下方式计算的：影响指标（公式 3）。

(a) 与 Java 的稳定趋势相比，.NET 平台呈现出负面趋势。(b) 人们对移动应用程序开发的兴趣增长速度快于 Web 开发。

(附录 A) 显示每个主题的趋势线，使用影响指标（公式 3）。这些趋势线可以指示人们对特定主题的兴趣是上升还是下降。现在，我们将更详细地分析这些主题的趋势。

首先，我们使用 Cox Stuart 趋势检验 (Cox and Stuart 1955) 来确定每个主题的影响力指标是增加或者减少随着时间的推移，使用标准的 95% 置信水平，达到统计学显著程度。简而言之，考克斯-斯图尔特趋势检验将时间序列中较早的数据点与较晚的数据点进行比较，以确定其趋势是上升还是下降，并使用米差异的大小来判断趋势是否显著。检验结果如表 2 所示，发现 17 个主题呈现上升趋势，甚至呈现不变的趋势（即既没有显著地上升，也没有显著地下降），16 个主题呈现下降趋势。

图 6 绘制了前 5 个上升和下降趋势，以影响第一个时间段和最后一个时间段之间的得分。图 6(a) 显示，随时间推移增幅最大的主题是表格数据相关、移动应用程序开发、图像/显示、Web 开发、和错误处理。这些主题每个都增长了 73% 以上

哦五

在过去 27 个月内,开发者的兴趣大幅增加。另一方面,图 6(b) 显示,随时间下降幅度最大的主题是工作/经验、学习/书籍、版本控制、项目/开源、和

.NET 框架。虽然这五个主题在数据集初期都具有相对较高的影响力,但随着时间的推移,它们被其他主题所取代,每个主题的影响力都下降了至少 50%。我们将在第 4 节进一步讨论这些趋势。

接下来我们利用趋势数据对两大发展领域:开发平台和部署平台进行详细的比较。
开发平台比较。目前使用的两个主要开发平台是 Microsoft .NET 和 Java (Evans Data Corporation 2011)。我们在图 7(a) 中比较了这两个平台。在 Stack Overflow 的初始阶段,.NET 框架-相关讨论 (Windows/Visual Studio 技巧和 .NET 框架) 寡不敌众 Java 相关的讨论,但随着时间的推移,.NET 相关讨论的趋势正在减少。

目标平台比较。我们比较了两个目标平台:网页和移动设备。从图 7(b) 可以看出,两个平台都呈现上升趋势。然而,尽管是一个较新的平台,移动应用程序开发 2010 年 4 月,移动应用程序相关主题的搜索量超过了网络相关主题,标志着开发人员对移动应用程序开发的兴趣迅速上升。

3.4 RQ4. 对特定技术的兴趣如何随时间变化?

比较各个主题的趋势,可以让我们深入了解这些主题的相对受欢迎程度。然而,每个主题也可以被视为一组相互竞争的技术。与某个主题相关的每种不同技术都有其自身的趋势。比较与特定主题相关的技术趋势,可以让我们更深入地了解开发者的兴趣。为了进行这种细粒度的分析,我们采用了 **技术影响指标** (公式 5) 来比较与某一主题相关的技术的影响。

图 8 展示了一个主题子集来说明结果,即数据库平台、移动应用开发、版本控制、学习、脚本语言和 Web 开发。我们在下面做了一些观察。

首先,我们观察到 SQL Server 和 MySQL 占主导地位数据库平台技术 (图 8(a))。此外,我们看到 MySQL 呈上升趋势,而 SQL Server 的趋势相对稳定。其他平台的趋势相对稳定,但总体影响较小。

如果是移动应用程序开发,我们可以清楚地看到 Android 平台自 2009 年 9 月以来的崛起 (图 8 (b))。这与 Android 1.5 平台的发布日期相吻合。iPhone 平台比 Android 更老,在 2009 年 9 月之前影响力更大。然而,我们可以看到两个平台的影响力在 2010 年 9 月左右趋于一致。由此我们可以说,在大约一年的时间里,Android 平台的影响力已经与 iPhone 相当,这可能归因于该项目的开源性质。与这两个平台相比,黑莓平台的影响力虽然稳定,但非常低。




图 8 针对特定主题内的技术趋势进行重点分析。(a) MySQL 呈上升趋势，正在迅速赶上 SQL Server。(b) Android 正在快速崛起。(c) Git 已超越 SVN。(d) 初学者对 C/C++、C# 和 Java 的提问比 Python、PHP 和 JavaScript 的提问更多。(e) Python 和 PHP 是更流行的脚本语言。(f) JavaScript 呈稳定趋势，而 jQuery 在 Web 开发中呈快速上升趋势。

在图 8(c) 中，我们绘制了 Git 与 SVN 两大主要版本控制系统的对比图。我们观察到，自 2008 年以来，Git 的影响力稳步上升，而 SVN 的影响力则相对稳定。Git 在 2010 年 1 月左右超越了 SVN。

2

Stack Overflow 的用户范围从新手到专业程序员。新手程序员经常会问一些关于学习编程语言的问题。因此，我们可以通过绘制以下图表来了解新手问得最多的编程语言。

各种语言的影响学习主题。我们发现 C/C++、C# 和 Java 的影响力高于 PHP、Python 和 JavaScript (图 8(d))。

我们还分析了脚本语言 (图 8(e))。准确地说, 我们绘制了 PHP (一种服务器端脚本语言)、Python 和 Perl (两种通用脚本语言) 以及 JavaScript (一种用于 Web 浏览器的脚本语言) 的趋势。从图中可以看出, PHP 和 Python 是首选语言。我们还注意到, 与另一种通用脚本语言 Python 相比, Perl 相对不那么受欢迎。然而, 一个令人惊讶的结果是, JavaScript 在脚本语言主题。这促使我们进一步研究 JavaScript 在另一个主题中的影响。

我们分析了“Web 开发”主题下不同的客户端和服务端技术 (图 8(f))。由此可见, JavaScript 的总体影响力高于 ASP.NET 和 PHP。此外, jQuery 的快速崛起也颇为引人注目, 它是一个流行的 JavaScript 库。jQuery 相较于普通 JavaScript 的优势, 例如 CSS 选择器以及易于为网页添加视觉效果, 可能正是其受欢迎程度的原因 (jQuery 2012)。

4 讨论

我们对 Stack Overflow 的分析使我们能够深入了解当前软件行业开发者的思维过程。我们发现, Web 和移动应用程序正在成为开发者的目标平台, 但移动平台领域的工具支持可能仍需完善。不同平台之间存在一些共同的交叉问题, 需要对这些平台进行进一步的研究和分析。此外, Stack Overflow 的知识和经验共享特性应该能够激励研究人员和供应商共同致力于利用知识库来创新地生成文档。最后, Stack Overflow 本身或许可以从帖子的上下文标记中受益, 从而更好地对帖子进行分类。

4.1 网络的主导地位

在所有主要的技术话题中, 我们发现与网络相关的讨论最为热门。仅与网络相关的讨论就分布在以下三个主题中, 这进一步佐证了这一点: 网页开发、网站设计/CSS 和 Web 服务/应用程序, 而其他主题则没有一个跨越多个主题。我们还在其他主题中发现了与网络相关的关键词 (见附录 A 中的表 1)。身份验证/安全主题包含与安全登录、会话管理和网站 cookie 相关的帖子; 脚本语言主题有与 PHP 相关的帖子, Java 主题中有与 JSP 相关的帖子。同样清楚的是 JavaScript 目前是现代 Web 2.0 网站的主要构建工具, 我们可以看到与 JavaScript 相关的几个词 (“javascript”、“jquery”和“ajax”在 Web 开发主题。MVC (模型-视图-控制器) 设计模式 (Gamma et al 1995) 在 Web 应用程序中的出现也显而易见, 因为我们发现 “mvc” 是 Web 服务/应用程序话题。

4.2 迈向移动开发

我们注意到，最近 iPhone 和 Android 等移动设备的使用量激增（尼尔森公司 2012），为开发人员创造了一个新的部署平台，正如移动应用程序话题。此外，我们还看到移动应用程序 2010 年 3 月左右，iOS 3.2 SDK for iPad 的发布恰逢其时（见图 7(b)）。这表明，越来越多的开发者选择移动设备作为目标平台，而非传统平台。结合上述三个 Web 应用主题，这表明，软件部署在“瘦客户端”架构下已成为一种趋势。

未来平台（例如 Google Play（2012））的功能也与我们的发现一致。通常，这些应用程序利用云服务器的计算能力，并将用户的计算机仅用作界面。移动设备领域的“应用程序”也遵循类似的设计原则，由于移动设备的计算能力有限，因此优先考虑小型、轻量级的软件。尽管这些结果表明开发者对移动应用程序的兴趣正在快速增长，但我们注意到，目前在开发者对移动应用程序的支持方面进行的学术研究非常有限。

4.3 洞察开发工具、平台和技术的使用情况

软件开发人员使用各种工具（包括 IDE、版本控制系统和测试框架）来支持他们的开发流程。这些工具的选择取决于目标平台的选择，而目标平台的选择通常由市场趋势决定。下文我们将基于对 Stack Overflow 数据的分析，探讨我们的观点。

在流行的 IDE 中，我们发现有一整套主题专门讨论微软的旗舰 IDE：Visual Studio。此外，.NET 框架也在其自己的主题中进行了讨论。然而，我们没有在单独的主题中发现任何其他 IDE 或框架。我们注意到，基于 Java 的 IDE（例如 Eclipse 和 Netbeans）以及基于 Java 的框架（例如 Spring 和 Hibernate）是热门的关键词和标签。Java 话题。然而，这些 IDE 和框架的讨论量都不如 Visual Studio 或 .NET，因此没有专门的话题。XCode（苹果用于开发 iOS 应用的 IDE）和 Android（谷歌用于开发移动应用的 SDK）也是如此。虽然我们注意到“xcode”和“android”出现在热门标签和关键词中，但它们本身尚未成为话题，尽管移动应用正在兴起。我们预计，在不久的将来，移动应用开发工具将引发更多讨论，并为这些工具和框架创建独特的话题。

虽然 Windows/Visual Studio 和 .NET 框架是不同的主题，我们发现这两个主题与 Java 当我们探讨第三个研究问题时（见图 7(a)）。其中一个原因可能是 MSDN 网络（2012）的蓬勃发展，它是 .NET 相关文档的中心，为 .NET 开发人员提供了丰富的资源。.NET 开发人员可能无法在 Stack Overflow 上找到令人满意的答案，因此转向其他地方。另一方面，开发人员离开 .NET 可能是因为与 Java 等免费开源替代方案相比，该框架具有商业和闭源的特性。

相比之下，Java相关讨论自2008年9月首次飙升后一直保持相对稳定的趋势。

4.4 跨领域开发人员的共同关注点

我们在 Stack Overflow 讨论中发现，许多开发者关注的问题在多个主题中是共通的。例如，正如我们在调查第二个研究问题时发现的那样，软件的用户界面是 Web 和移动应用程序开发中都普遍关注的问题。这可能表明，用户界面设计是跨平台开发者普遍关注的问题。工具开发人员和研究人员或许应该基于以用户为中心的分析 and 开发者讨论，进一步研究这个问题，以便开发出更好的 UI 开发工具。另一个跨领域的问题是身份验证和安全性。我们发现，它是网络、Web 应用程序和数据库平台等多个应用领域都关注的问题。然而，我们发现缺乏关于移动设备安全性的讨论，尽管移动应用程序开发本身就是 Stack Overflow 上的一个主题。研究人员已经对移动设备安全领域表现出浓厚的兴趣（Becher 等人，2011）。虽然开发真正安全的软件本身就是一个研究课题（McGraw，2002），但我们相信，在 IDE 中内置专门定制的支持，并在 API 文档中添加额外的安全措施，将使开发人员的开发过程更加轻松，并对产品的安全性和可靠性建立一定程度的信心。

4.5 拥抱开源

我们在发现的许多主题中都发现了对开源软件的引用。例如，我们发现关于开源 Android 平台的讨论在商业 iPhone SDK 发布后迅速赶上。这表明开发者比商业平台更迅速地接受了开源平台。我们在 Java 及其相关工具的案例中也发现了类似的结果：与商业 .NET 框架的下降趋势相比，它们的上升趋势较为缓慢。在数据库领域，我们看到了开源 MySQL DBMS 的崛起。在版本控制主题中，我们找到了与 Git 和 SVN（两个开源版本控制系统）相关的关键词。相比之下，我们没有找到任何与其他商业替代方案（例如 Perforce（2012））相关的关键词。此外，我们在前十个标签中只找到一个标签（tfs，指的是微软的 Team Foundation Server），而与开源版本控制系统相关的标签有 5 个（svn、git、mercurial、tortoisetsvn、git-svn）（见附录A中的表3）。这是开源软件在软件开发一些相关领域的成熟度指标，即：数据库、IDE、版本控制和移动应用程序。

4.6 知识共享与学习平台

虽然 Stack Overflow 本质上以技术主题为主，但我们 also 发现一些非技术主题。其中一个主题是工作/经验主题，其中

开发人员讨论他们的工作环境、当前的就业市场以及他们的职业选择。另一个话题是学习新手开发者通常会在这类问题上寻求针对特定问题、特定语言或平台的“入门指南”。我们最初分析 Stack Overflow 时，原本以为只会找到技术主题。然而，这两个主题展现了开发者讨论主题的多样性和广度。此外，在对第二个研究问题的分析中，我们发现工作/经验在我们分析的 10 个问题主题中，有 6 个将“问题”作为主要答案主题之外的次要答案主题。这表明开发人员更有可能将特定问题与自身经验联系起来，并尝试根据该经验进行回答。

与学习这些问题表明，此类主题的知识和培训有限（见图 5(j)）。例如，对本科课程的调查显示，迫切需要性能/优化主题（Díaz-Herrera 2005；Dugan 2004）。通过对 Stack Overflow 的分析，我们能够亲眼目睹这种需求对日常实践的影响。此外，我们观察到，关于构建系统的知识（即编译构建系统（主题）的诸多问题引出了关于构建系统的问题。这种发现的关系表明，构建系统的研究需求很大，因为它们开发人员工作实践的重要组成部分，尽管目前对构建系统的研究有限 (McIntosh et al 2011)。

4.7 生成更好文档的方向

开发者访问 Stack Overflow 是为了寻找他们所面临特定问题的答案。例如，一位开发者可能会因为 Visual Studio 安装遇到问题而向 Stack Overflow 提问。这可能会激励工具开发者为其产品提供清晰全面的文档。通过对第一个研究问题的分析，我们可以大致了解开发者面临的问题领域。例如，……NET 框架和 Windows/Visual Studio 是我们分析发现的两个主题。这表明，尽管有像 MSDN (2012) 这样近乎全面的文档，开发人员仍然依赖于同行的解答。这可能是为 .NET 框架生成更用户友好的文档的一个动机。在调查第二个研究问题的过程中，我们还发现了一些交叉关注点。这些关系有助于揭示主题之间意想不到的关系，并指出了在 UI 开发和安全等方面需要进行更多研究和文档编制。在框架和工具的文档中，更多关于用户界面开发的信息可能会有所帮助。我们还发现工作/经验作为答案中的次要主题之一版本控制 问题。这表明有必要记录软件组织中版本控制系统使用的最佳实践，以便开发人员能够从整个行业的多样化经验中受益。最后，通过对第三和第四个研究问题进行广泛而有针对性的趋势分析，我们了解了平台和技术的相对流行程度。这些信息可以进一步研究。例如，通过进一步分析与某个领域中特定技术（例如 PHP）相关的问题，研究人员和工具开发人员可以发现开发人员在使用过程中面临的常见问题。

该领域的技术。这些信息可用于生成更有针对性的文档来解决这些问题。

4.8 上下文标记

Stack Overflow 允许用户使用关键词标记问题，以便对问题进行分类。然而，用户创建的标签数量过多，难以管理。我们利用主题建模技术，将帖子划分为多个类别。此外，这为我们研究某些技术在多个主题中的影响提供了基础。JavaScript 在两个领域的趋势分析脚本语言和Web 开发主题强化了我们的假设：单靠标签可能无法有效识别主题并追踪技术变化，因为与某项技术相关的标签可能涵盖多个主题。因此，通过使用主题建模，我们可以识别并比较一项技术在不同领域的影响。像 Stack Overflow 这样的网站可以通过使用分层标记方案（Heymann 和 Garcia-Molina 2006）受益于这种方法，该方案利用从问题中获取的上下文将其归入更广泛的类别，然后使用用户指定的标签对该问题进行进一步分类。

5 个对有效性的威胁

我们现在概述了对我们的结果有效性的潜在内部和外部威胁。

*内部有效性。*我们尝试使用成熟的工具来提取和预处理数据（例如 PHP 的内置 XML 解析器、Perl 的Lingua::Stem词干库）、执行 LDA（即 MAL-LET（McCallum 2002））并计算我们感兴趣的指标（即 R 编程环境）。

选择 LDA 的最优参数设置是一项艰巨的任务，目前尚无已知的通用解决方案 (Grant and Cordy 2010; Wallach et al 2009)。虽然我们尝试了不同的主题数量值 (k)，我们无法确定我们选择的值对于我们进行的分析是否是最优的。此外，我们的文档成员资格截止阈值， δ ，会影响我们的研究结果。然而，实验发现，我们的结果对 δ ，我们注意到所有主题都受到相同的阈值约束。

*外部有效性。*对我们结果外部效度的一个潜在威胁是，我们的分析仅涵盖了 Stack Overflow 的数据集。尽管 Stack Overflow 是面向开发者的顶级问答网站之一，但我们仍需要进一步研究，才能确定我们的研究结果是否适用于其他问答网站、编程论坛以及不同的开发者群体。

我们的趋势分析结果仅基于我们研究的数据集的时间线。我们的方法不包含预测模型，因此无法用于预测未来数据（例如，新技术带来的变化或某些产品的消亡）。

主题活跃度的持续增长可能由多种不同因素造成：(a) 该主题较新/热门，开发者乐于讨论；(b) 该主题的文档较差且难以理解，开发者必须寻求在线帮助。（请注意，在后一种情况下，该主题必须仍然足够热门，开发者才认为值得讨论。）我们的方法和结果并未区分这两种相关情况，尽管这样做对某些方面可能有所帮助。

6 相关工作

我们将相关工作总结为四类：对问答网站的一般研究；对 Stack Overflow 的具体研究；对其他开发者社交平台的研究；以及使用 LDA 研究软件工程数据趋势。

一般问答网站。先前的研究主要基于用户的社交互动来分析通用问答网站。Gyöngyi 等人（2008）分析了面向大众的问答网站雅虎问答 (Yahoo! Answers) 中用户行为的几个方面。作者使用每个预定义顶级类别中的问题和答案数量来确定每个类别的受欢迎程度。Adamic 等人（2008）也分析了雅虎问答，利用内容和用户互动将顶级类别聚类为三个更广泛的类别。与这些研究不同，我们没有使用现有标签，而是使用统计主题模型 (LDA)，从帖子的文本内容中自动发现主题，并采用时间指标来确定主题随时间变化的受欢迎程度。

堆栈溢出。研究人员已开始分析 Stack Overflow，对其问题进行分类（Treude 等人，2011 年）并确定其设计特点（Mamykina 等人，2011 年）。Treude 等人（2011 年）分析 Stack Overflow，找出主题，并将问题分为不同类型，如“如何做”、“差异”、“环境”等。作者将他们的分析应用于 15 天的帖子，使用用户创建的标签来识别主题。他们根据随机数据样本手动编码问题。相比之下，我们将基于 LDA 的自动化方法应用于 27 个月的帖子，并使用标签作为辅助基础，以推断更广泛主题类别下不同技术的趋势。Mamykina 等人（2011 年）确定了导致 Stack Overflow 流行的核心设计特点：基于积分的声誉系统、设计团队对社区的积极参与以及单一领域关注。此外，作者根据用户在 Stack Overflow 上的活动频率对其进行了分类（例如，社区活跃用户、低调用户）。我们关注的不是用户活跃度，而是用户生成的文本内容，以便提取主要的讨论主题。

其他社交平台。研究人员分析了其他数据集和社交平台，例如代码搜索引擎使用日志和开发者博客，以找出开发者感兴趣的主体。特别是，Bajracharya 和 Lopes (2012) 分析了一个流行代码搜索引擎的日志，以发现主要的代码搜索主题。与我们的技术类似，他们将 LDA 应用于代码搜索引擎的使用日志。他们分析发现的一些主题与

我们的研究结果与他们的发现相似（例如，数据结构、文件、GUI、网络、解析/编译、安全性和字符串）。然而，他们的分析基于特定的开发者群体，即 Java 程序员。相比之下，我们的分析考虑了使用各种不同编程语言和平台的开发者。此外，我们同时分析问题和答案，而前述研究仅分析问题内容（即搜索查询）。此外，他们的研究侧重于开发者的特定需求：为特定问题查找源代码示例。相比之下，我们对基于社区的问答网站的分析从更广泛的视角满足了开发者的需求。

在另一项研究中，Pagano 和 Maleej (2012) 使用主题模型分析了开发人员的博客活动，以发现这些博客中的主题。他们特别分析了活跃于特定代码库（例如 Eclipse、PostgreSQL、GNOME 和 Python）的开发人员撰写的博客。相比之下，我们的研究考虑了具有不同背景和不同经验水平的开发人员。

潜在狄利克雷分配。 LDA 此前曾被用于分析软件工程数据中的趋势。Hindle 等人 (2009) 将 LDA 应用于版本控制系统中的提交日志消息，以确定开发人员在特定时间点正在处理的主题，并了解开发趋势的变化。Neuhaus 和 Zimmerman (2010) 将 LDA 应用于一个知名的漏洞数据库，以发现特定安全漏洞随时间变化的趋势。Thomas 等人 (2010) 将 LDA 应用于软件演化，后来又提出了一种 LDA 变体，可以更好地检测源代码中的主题趋势 (2011)。我们的方法与上述三种方法不同，我们将 LDA 应用于一个完全不同的领域，即开发者问答网站。LDA 还能帮助我们克服 2.3 节中提到的标签问题。此外，我们还介绍了一些技术，用于查找主题对之间的问答关系，并根据各个技术的基础主题确定其影响。

7 结论和未来工作

本文提出了一种方法，用于发现和量化 Stack Overflow（一个拥有数百万活跃用户的热门问答网站）中的主题和趋势。我们的方法基于 LDA，这是一种广泛应用的统计主题模型，它可以发现主题取自 Stack Overflow 的文本内容。我们定义了各种指标来量化主题及其随时间的变化，从而深入了解 Stack Overflow 上的讨论。

我们的分析大致反映了当代开发者的需求。例如，我们发现移动应用开发正在蓬勃发展，其增长速度快于 Web 开发。Android 和 iPhone 开发都比黑莓开发更为普遍。PHP 脚本语言正变得非常流行，远超 Perl 等语言。Java 在编程语言和 API 领域始终占据主导地位，而 .NET 框架则略有下降。Git 在 VCS 流行度竞赛中已经超越 SVN，而 MySQL 则是过去几年最热门的数据库管理系统 (DBMS)。

工具开发者可以利用我们的分析结果来调整他们的工具，或者决定支持哪些技术。例如，

Git 表明现代开发环境应该支持 Git。此外，Android 最近的流行也表明开发者需要更好的工具支持来开发 Android 应用程序。

Stack Overflow 团队可以利用我们的分析更好地了解用户生成的内容。了解当前有哪些主题以及哪些主题在特定时间段内比较热门，有助于网站内容的审核。例如，如果当前 90% 的帖子都只涉及两个主题，那么 Stack Overflow 就可以专门针对这两个主题创建衍生的问答网站。

我们可以在很多方面扩展这项工作。我们计划分别对问题和答案进行主题分析，以便从整体分析中发现不同的主题。我们还计划将LDA应用于更短的帖子时间间隔（例如 1-3 个月），这可能有助于发现仅在这几个月出现但随后消失的主题。我们计划尝试其他的 *变体*，以期找到更细粒度的主题，从而揭示更多见解。我们的技术可以与其他研究人员（Shah 和 Pomerantz, 2010）提出的统计模型相结合，以确定答案的质量。我们的方法也可以应用于其他开发者资源，例如门户网站、博客和论坛；我们可以将这些资源与 Stack Overflow 进行交叉引用，以确定这些媒介中是否存在类似的趋势。

8 致谢

我们要感谢匿名评论者的宝贵反馈。

主题列表

表 1LDA 发现的 40 个主题。除了 LDA 发现的主题中的热门词汇外，我们还提供了手动创建的主题名称来简要描述每个主题。

主题名称	热门 LDA 词
编码风格/实践	代码案例设计不同实现方法编写依赖示例
问题/解决方案	工作问题代码解决方案罚款问题解决工作罚款错误的想法
质量保证和链接	问题 回答 发表评论 文章 编辑 链接 示例 查找 阅读
功能	函数类型变量值参数调用传递返回参数
工作/经验	开发工作时间人员软件战争年戴公司产品工作
面向对象编程	类方法对象调用实现实例接口创建静态
UI 开发	控制视图事件按钮点击设置用户选项卡创建添加
文件操作	文件目录路径文件夹创建读取上传打开写入复制
网站设计/CSS	css 浏览器元素 div 样式 html Firefox Flash 工作 JavaScript
字符串操作	字符串字符编码格式空格转换字quot输入文本
学习	语言编程学习书籍 C++ C# Java C 编写阅读
代码片段	时间调用代码循环秒执行块检查设置之前
数据库平台	数据库表 SQL 数据服务器插入数据库 SQL 服务器记录更新
数值运算	value number arrai integ bit result int 计算时间 oper
Web 开发	表单 javascript jquery ajax 有效函数提交加载发布调用
编译	编译命令 librari c c++ linux 代码程序 rail rubi
图像/显示	图像颜色绘制点尺寸屏幕动画设置背景显示
SQL	查询表 SQL 结果行连接选择返回列过程
联网	服务器连接客户端请求http发送主机网络响应端口
身份验证/安全	用户会话站点安全访问密码帐户身份验证登录 cookie
对象相关映射	对象属性模型集实体值字段映射属性创建
性能/优化	执行时间优化更快大内存大小速度慢缓存
文本相关	文本文档标签 HTML 内容模板搜索链接 PDF 编辑器
Windows/VS 技巧	窗口安装 Visual Studio 应用程序 Visual Studio dll 调试设置
数据结构/算法	列表项元素排序数组节点顺序迭代收集树
移动应用程序开发	应用程序应用程序iPhone设备视频Android API开发手机
项目/开源	项目源代码构建工具代码开放产品源代码开放源代码 _
.NET框架	C# 版本网络支持框架汇编组件功能库
脚本语言	脚本 php python 模块包 perl 安装 django 导入函数
表格数据相关	选择行列值表字段单元格显示 Excel 框
线程/进程	线程进程消息锁定电子邮件发送任务队列调用等待
Web服务/应用程序	服务 Web 应用程序 MVC 应用程序 Web 服务 WCF 站点 Web 应用程序客户端
内存/指针	内存指针对象分配数组堆栈地址引用复制缓冲区
错误/异常	错误日志消息代码抛出失败警告错误消息捕获调试
正则表达式	url 匹配 express 正则表达式 正则路由 正则表达式规则模式
Java	java eclips 插件应用程序 jar spring 配置类 servlet maven
密码学	数据kei存储散列结构加密字典值读取生成器
XML	xml cach 串行解析器 namespac json xml 文件属性元素
版本控制	更改存储库分支 svn 提交版本 git 合并工作控制
测试	测试单元代码单元测试编写模拟工作案例测试代码失败 _

表 2 话题分享和趋势。我们展示 分享指标 (公式 1)、包含问题 (Q) 和答案 (A) 主题的帖子百分比、趋势 (使用 Cox Stuart 趋势检验 $\alpha=0.05$) 以及该主题影响力随时间变化的趋势线。

主题名称	分享 (%)	Q (%)	A (%)	趋势	趋势线
编码风格/实践	4.5	14.3	85.7	↓	
问题/解决方案	4.5	36.5	63.5	↑	
质量保证和链接	3.8	17.3	82.7	↓	
功能	3.4	19.7	80.3	↑	
工作/经验	3.3	17.6	82.4	↓	
面向对象编程	3.2	21.7	78.3	↓	
UI 开发	3.1	36.9	63.1	↑	
文件操作	2.8	31.4	68.6	–	
网站设计/CSS	2.6	30.5	69.5	↑	
字符串操作	2.5	23.0	77.0	–	
学习	2.5	19.8	80.2	↓	
代码片段	2.4	22.8	77.2	↑	
数据库平台	2.4	32.4	67.6	↓	
数值运算	2.4	24.2	75.8	↑	
Web 开发	2.3	31.8	68.2	↑	
编译	2.3	24.5	75.5	↓	
图像/显示	2.3	39.1	60.9	↑	
SQL	2.2	30.1	69.9	–	
联网	2.2	30.1	69.9	↓	
身份验证/安全	2.1	28.2	71.8	↑	
对象相关映射	2.1	32.7	67.3	–	
性能/优化	2.1	18.9	81.1	↓	
文本相关	2.1	32.9	67.1	↑	
Windows/VS 技巧	2.1	32.7	67.3	↓	
数据结构/算法	2.0	25.2	74.8	↑	
移动应用程序开发	1.9	41.1	58.9	↑	
项目/开源	1.9	23.6	76.4	↓	
.NET 框架	1.9	22.5	77.5	↓	
脚本语言	1.8	27.9	72.1	↑	
表格数据相关	1.8	45.4	54.6	↑	
线程/进程	1.6	25.3	74.7	↓	
Web 服务/应用程序	1.6	36.3	63.7	↓	
内存/指针	1.6	17.5	82.5	–	
错误/异常	1.6	40.7	59.3	↑	
正则表达式	1.6	23.3	76.7	↑	
Java	1.5	28.8	71.2	–	
密码学	1.3	24.6	75.4	↑	
XML	1.1	27.0	73.0	–	
版本控制	1.1	24.1	75.9	↓	
测试	0.9	21.5	78.5	↓	

表 3与每个主题相关的热门 Stack Overflow 标签。对于每个主题，标签按以下顺序排序： 标签分数指标按降序排列。 -

主题名称	热门 Stack Overflow 标签
编码风格/实践	c# java .net c++ php javascript python
问题/解决方案	c# php javascript jquery javaasp.net iphone c++
质量保证和链接	c# php java .net c++ javascript asp.net
功能	c# c++ javascript php java .net c
工作/经验	c# php java .net asp.net sqlcareer-development mysql
面向对象编程	c# java .net c++ objective-c php python
UI 开发	c# iphone wpf asp.net jquery javascript .net
文件操作	c# php java asp.net .net python c++
网站设计/CSS	css jquery javascript html flash internet-explorer asp.net
字符串操作	时间: 2019-03-27 标签: c#phpjavapythonregexstring
学习	c# c++ java c python 书籍 .net
代码片段	c# java php javascript .net jquery c++
数据库平台	sql-server sql mysql 数据库 c#php sql-server-2005 oracle
数值运算	c# php java c++ c 数组 python
Web 开发	jquery javascript ajax asp.net php html c#
编译	c++ c linux ruby-on-rails ruby java gcc
图像/显示	iphone c# android 图像 java javascript wpf
SQL	SQL MySQL SQL 服务器 C# PHP TSQL Linq
联网	c# java php asp.net .net 套接字 http
身份验证/安全	php asp.net c# 安全 ruby-on-railsjava 身份验证 .net
对象相关映射	时间: 2019-03-17 标签: c#netjavanhibernateruby-on-railsasp.net-mvc
性能/优化c# 性能 java .net c++ php 算法	
文本相关	HTML php C# javascript asp.net java jquery
Windows/VS 技巧	c# .net windows visual-studio c++ visual-studio-2008 asp.net
数据结构/算法	c# java python php jquery c++
移动应用程序开发	iPhone Android Objective-C iPhone SDK Java C# Xcode
项目/开源	c# .net java visual-studio asp.netc++ visual-studio-2008 msbuild
.NET框架	c# .net asp.net delphi java vb.net 报告服务
脚本语言	php python perl django mysqljavascript apache linux
表格数据相关	c# asp.net jquery javascript iphone excel php
线程/进程	多线程 c# java .net c++ 电子邮件 php
Web服务/应用程序	c# asp.net wcf .net web-services asp.net-mvc java
内存/指针	时间: 2019-03-27 标签: c++c#iphoneobjective-cjavamemory-management
错误/异常	c# java php asp.net c++ .net python
正则表达式	正则表达式 php c# javascript asp.net mod-rewrite java
Java	java eclipse spring maven-2 tomcatjsp hibernate netbeans
密码学	c# java php .net python iphone 加密
XML	XML C# Java XSLT .NET PHP
版本控制	svn git 版本控制 mercurial tortoissvn 分支合并
测试	单元测试 c# 测试 java .net ruby-on-rails tdd

参考

- Adamic LA, Zhang J, Bakshy E, Ackerman MS (2008) 知识共享和雅虎问答：每个人都知道一些事情。摘自：《第17届万维网国际会议论文集》，第665-674页
- Apache Subversion (2012) 网址 <http://subversion.apache.org/>
- Bajracharya S, Lopes C (2012) 分析和挖掘代码搜索引擎使用日志。实证研究
软件工程 17: 424-466
- Barnard K, Duygulu P, Forsyth D, De Freitas N, Blei DM, Jordan MI (2003) 匹配词和图片。机器学习研究杂志 3: 1107-1135
- Becher M, Freiling FC, Hoffmann J, Holz T, Uellenbeck S, Wolf C (2011) 移动安全迎头赶上？揭秘移动设备安全的关键所在。摘自：IEEE 安全与隐私研讨会，第 96-111 页
- Blei DM, Lafferty J (2009) 主题模型。文本挖掘：理论与应用。Taylor 和
弗朗西斯，英国伦敦
- Blei DM, Ng AY, Jordan MI (2003) 潜在狄利克雷分配。机器学习杂志
研究 3: 993-1022
- Cox D, Stuart A (1955) 位置和离散趋势的快速符号检验。Biometrika
42(1/2):80-95
- Diaz-Herrera JL (2005) 计算与信息科学：学科、职业和未来
方向。参见：ACM 东南地区会议
- Dugan RF (2004) “我的教授告诉我的性能谎言：软件性能教学案例”
面向本科生的软件工程课程。《第四届软件与性能国际研讨会论文集》，第 37-48 页
- Evans Data Corporation (2011) 软件开发平台 - 2011 年排名。网址
<http://www.evansdata.com/reports/viewReleaseDownload.php?reportID=19>
- Gamma E, Helm R, Johnson R, Vlissides J (1995) 设计模式：可重用元素
面向对象软件。Addison-Wesley，马萨诸塞州波士顿
- Geman S, Geman D (1984) 随机松弛、吉布斯分布和贝叶斯
图像恢复。IEEE 模式分析与机器智能学报，第 721-741 页
- Git SCM (2012) 网址 <http://git-scm.com/>
- Google Play (2012) 网址 <https://play.google.com/about/features>
- Grant S, Cordy JR (2010) 估计源代码中潜在概念的最佳数量
分析。见：第十届源代码分析与操作国际工作会议论文集，第 65-74 页
- Griffiths TL, Steyvers M (2004) 寻找科学主题。美国国家科学院院刊
科学 101: 5228-5235
- Griffiths TL, Steyvers M, Tenenbaum JB (2007) 语义表征专题。心理
逻辑评论 114(2):211-244
- Gyöngyi Z, Koutrika G, Pedersen J, Garcia-Molina H (2008) 质疑雅虎！答案。在：
第一届网络问答研讨会论文集
- Hall D, Jurafsky D, Manning CD (2008) 使用主题模型研究思想史。在：
自然语言处理经验方法会议论文集，第 363-371 页
- Hassan AE (2008) 软件存储库挖掘的未来之路。《软件前沿》
维护，第 48-57 页
- Heymann P, Garcia-Molina H (2006) 合作创建社区等级税收
社会化标签系统中的个体差异。技术报告 2006-10，斯坦福信息实验室，网址 <http://ilpubs.stanford.edu:8090/775/>
- Hindle A, Godfrey MW, Holt RC (2009) 热门与冷门：窗口化开发者话题
分析。见：第 25 届国际软件维护会议论文集，第 339-348 页
- jQuery (2012) URL <http://docs.jquery.com/jquery> 的工作原理
- Kuhn A, Ducasse S, Girba T (2007) 语义聚类：识别源代码中的主题。
信息与软件技术 49(3):230-243
- Linstead E, Lopes C, Baldi P (2008) 潜在狄利克雷分配在分析中的应用
软件演进。《第七届机器学习与应用国际会议论文集》，第 813-818 页

- Mamykina L, Manoim B, Mittal M, Hripcsak G, Hartmann B (2011) 设计经验
西方最快的问答网站。摘自：《计算机系统人为因素会议论文集》，第 2857-2866 页
- Manning CD, Raghavan P, Schtze H (2008) 信息检索简介。剑桥
大学出版社，美国纽约州纽约市
- McCallum A (2002) MALLET：一种机器学习语言工具包。网址
<http://mallet.cs.umass.edu>
- McGraw G (2002) 构建安全软件：胜过保护劣质软件。IEEE 软件
器皿 19(6):57-58
- McIntosh S, Adams B, Nguyen TH, Kamei Y, Hassan AE (2011) 构建的实证研究
维护工作。见：第 33 届国际软件工程会议论文集，第 141-150 页
- Mei Q, Shen X, Zhai C (2007) 多项主题模型的自动标记。出处：会议录
第 13 届国际知识发现与数据挖掘会议论文集，第 490-499 页
- Microsoft 开发者网络 (2012) URL <http://msdn.microsoft.com/en-us/> Microsoft SQL Server (2012)
URL <http://www.microsoft.com/sqlserver/en-us/default.aspx> Microsoft Visual Studio (2012) URL
<http://msdn.microsoft.com/en-us/vstudio>
- MySQL (2012) 网址 <http://www.mysql.com/>
- Neuhaus S, Zimmermann T (2010) 基于 CVE 主题模型的安全趋势分析。在：
第 21 届国际软件可靠性工程研讨会论文集，第 111-120 页
- 尼尔森公司 (2012) 《移动媒体报告：媒体现状》。网址
<http://www.nielsen.com/content/dam/corporate/us/en/reports-downloads/2011-Reports/state-of-mobile-Q3-2011.pdf>
- Oracle Java (2012) 网址 <http://www.java.com/en/>
- OSS Watch (2012) 运行社区主导项目的必备工具。网址：<http://www.oss-watch.ac.uk/resources/communitytools.xml>
- Pagano D, Maalej W (2012) 开源社区如何做博客？实证软件环境
工程，第 1-35 页
- Perforce (2012) 网址 <http://www.perforce.com/>
- Porter MF (1997) 后缀剥离算法。摘自：《信息检索读物》，
Morgan Kaufmann Publishers Inc.，美国加利福尼亚州旧金山，第 313-316 页 Pressman RS
(2005) 软件工程：实践者的方法。McGraw-Hill Shah C, Pomerantz J (2010) 评估和预测社区问答
中的答案质量。
出处：第 33 届信息检索研究与发展国际会议论文集，第 411-418 页
- Stack Overflow (2012a) 网址 <http://www.stackoverflow.com>
- Stack Overflow (2012b) Stack Overflow Creative Commons 许可证数据转储。网址
<http://blog.stackoverflow.com/2009/06/stack-overflow-creative-commons-data-dump/> Tan C,
- Wang Y, Lee C (2002) 使用二元语法增强文本分类。信息
加工与管理 38: 529-546
- Thomas SW (2012a) 网址 <http://research.cs.queensu.ca/~托马斯/>
- Thomas SW (2012b) 利用主题模型挖掘软件存储库。Tech. Rep. 2012-586,
皇后大学计算机学院
- Thomas SW, Adams B, Hassan AE, Blostein D (2010) 验证主题模型的使用
用于软件演化。见：第十届源代码分析与操作国际工作会议论文集，第 55-64 页
- Thomas SW, Adams B, Hassan AE, Blostein D (2011) 建模主题的演变
源代码历史。载于：第八届软件存储库挖掘工作会议论文集，第 173-182 页
- Treude C, Barzilay O, Storey M (2011) 程序员如何提问和回答
网络？出处：第 33 届国际软件工程大会论文集，第 804-807 页
- Wallach HM, Murray I, Salakhutdinov R, Mimno D (2009) 主题评估方法
模型。参见：第 26 届国际机器学习会议论文集，第 1105-1112 页
- Yahoo! 问答 (2012) 网址 <http://answers.yahoo.com>